

AGH

AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ ZARZĄDZANIA

**Sprawozdanie z projektu II – Zastosowanie Sztucznych Sieci Neuronowych w
prognozowaniu cukrzycy**

Grupa projektowa: *Małgorzata Balwierz, Izabela Gula, Laura Cygan, Magdalena Chmaj, Wiktoria Bąk*

Kierunek: *Informatyka i ekonometria (stacjonarne)*

Przedmiot: *Inteligencja Obliczeniowa*

Kraków, 2025

Wstęp do projektu

Cukrzyca jest jedną z najczęściej diagnozowanych chorób na świecie i może prowadzić do poważnych problemów zdrowotnych, dlatego też tak istotna jest jej wczesna diagnoza, aby móc wdrożyć leczenie i poprawić jakość życia pacjenta. Celem naszego projektu jest zbudowanie modelu sztucznej sieci neuronowej, który pomoże przewidzieć, czy dana osoba może mieć cukrzycę, czy nie ma takiego ryzyka. W tym celu wykorzystamy dane zawierające takie informacje jak liczba ciąż, poziom glukozy, ciśnienie krwi, poziom tkanki tłuszczowej, wskaźnik BMI, wskaźnik rodzinnej historii cukrzycy oraz wiek pacjenta. Dane zostały pobrane ze strony <https://www.kaggle.com/>.

Dzięki zastosowaniu sztucznych sieci neuronowych przeanalizujemy dane i nauczymy model rozpoznawania wzorców, dzięki czemu będzie możliwe zbadanie ryzyka zachorowania na cukrzycę.

I. Problem:

Dane, które wykorzystujemy w projekcie, zawierają informacje o 8 różnych cechach pacjentów, takich jak liczba ciąż, poziom glukozy, ciśnienie krwi, poziom tkanki tłuszczowej, wskaźnik BMI, wskaźnik rodzinnej historii cukrzycy czy wiek. Na początku dokładnie przejrzałyśmy cały zestaw danych i usunęłyśmy pozycje, w których brakowało wartości. Końcowy zestaw składający się z 1035 pełnych wpisów wykorzystamy do stworzenia i sprawdzenia działania naszego modelu.

II. Przegląd literatury:

Problem, którego się podjęłyśmy jest opisywany w wielu opracowaniach naukowych.

Literatura:

1. https://philpapers.org/archive/EL_DPU-5.pdf
2. <https://onlinelibrary.wiley.com/doi/full/10.1155/2021/5525271>
3. <https://www.mdpi.com/2075-4426/13/3/406>
4. <https://link.springer.com/article/10.1186/s13638-020-01765-7>
5. <https://tiny.pl/v-7w21fm>

Pierwsza pozycja przytoczonej przez nas literatury “Diabetes Prediction Using Artificial Neural Network “ została wydana w 2018 roku przez Department of Information Technology, Faculty of Engineering & Information Technology, Al-Azhar University - Gaza, Palestine. Publikacja przedstawia zastosowanie sztucznych sieci neuronowych (ANN) w przewidywaniu wykrywania cukrzycy. W badaniu wykorzystano 9 cech (dane wejściowe) takich jak: liczba ciąż, poziom glukozy w osoczu po 2 godzinach w teście tolerancji glukozy, rozkurczowe ciśnienie krwi, grubość fałdu skórno tricepsa (w mm), poziom insuliny w surowicy po 2 godzinach, BMI, funkcja dziedziczności cukrzycy, wiek, czy dana osoba ma cukrzycę (1/0). Dane wejściowe zawierały 1004 próbki, w tym 767 przykładów treningowych i 237 walidacyjnych. Sieć neuronowa składała się z 8 wejść, 3 warstw ukrytych i jednego wyjścia. Wyniki pokazały, że model osiągnął dokładność 87,3%, średni błąd wynosił 0,010, a liczba cykli treningowych to 158 000. Najbardziej wpływowe czynniki w przewidywaniu cukrzycy to poziom glukozy i wskaźnik masy ciała.

Druga pozycja "An Improved Artificial Neural Network Model for Effective Diabetes Prediction" z 2021 roku dotyczy badania przeprowadzonego przez Deanship of Scientific Research, King Saud University. Dotyczy zastosowania sztucznych sieci neuronowych (ANN) w przewidywaniu cukrzycy na podstawie zestawu danych Pima Indian Diabetes (PID). Dane pochodziły z Narodowego Instytutu Cukrzycy, Układu Pokarmowego i Chorób Nerek i obejmowały 768 przypadków kobiet w wieku powyżej 21 lat z Arizony. Dane zawierały 8 zmiennych diagnostycznych, takich jak liczba ciąż, poziom glukozy, ciśnienie krwi, BMI, insulina, wiek i funkcja obciążenia genetycznego cukrzycą. Model ANN był trenowany testując różne liczby neuronów w warstwie ukrytej (od 5 do 50), przy stałym współczynniku uczenia (0,25) i współczynniku pędu (0,5). Przeprowadzono 5000 epok treningowych. Model osiągnął najwyższą skuteczność przewidywania (93%) przy zastosowaniu 20 neuronów w warstwie ukrytej. Wyniki wskazują, że poziom glukozy we krwi po 2 godzinach w doustnym teście tolerancji glukozy był najbardziej znaczącym czynnikiem w diagnozowaniu choroby, natomiast istotnymi okazały się liczba ciąż oraz BMI.

Trzecia przytoczona przez nas publikacja "Predicting the Onset of Diabetes with Machine Learning Methods" opublikowany w 2023 roku w czasopiśmie "Journal of Personalized Medicine". W tym badaniu wykorzystano Microsoft Machine Learning Studio do trenowania modeli różnych rodzajów sieci neuronowych, a wyniki wykorzystano do porównania zdolności różnych parametrów cukrzycy. Analizowano dane 15 000 kobiet w wieku od 20 do 80 lat, które były pacjentkami miejskiego centrum medycznego w Tajpej w latach 2018–2022. Rozważano osiem cech: liczbę ciąż, poziom glukozy w osoczu, rozkurczowe ciśnienie krwi, grubość fałdu skórno, poziom insuliny, wskaźnik masy ciała (BMI), funkcję dziedziczności cukrzycy oraz wiek. Model ANN uzyskał wysoką skuteczność, osiągając dokładność równą 0.908. Wyniki wskazały, że najbardziej wpływowe zmienne w przewidywaniu wystąpienia cukrzycy to: poziom glukozy w osoczu, BMI, liczba ciąż, wiek.

Czwarta publikacja to artykuł "A Novel Neural Network Based Model for Diabetes Prediction Using Optimized Sine Cosine Algorithm" opublikowany w 2020 roku przedstawia model predykcji cukrzycy oparty na sztucznych sieciach neuronowych (ANN) optymalizowanych za pomocą algorytmu sinus-cosinus. Badanie wykorzystało dane z publicznie dostępnego zbioru Pima Indian Diabetes Database (PIDDD), który zawiera informacje medyczne dotyczące 768 kobiet z plemienia Pima w wieku od 21 lat, w tym 268 przypadków cukrzycy. Badane cechy to: liczba ciąż, poziom glukozy, ciśnienie krwi, grubość fałdu skórno tricepsa, poziom insuliny, BMI, funkcję dziedziczności cukrzycy, wiek. Model optymalizowany algorytmem sinus-cosinus osiągnął dokładność 88,7% w przewidywaniu wystąpienia cukrzycy. Analiza wskazała, że poziom glukozy, wskaźnik masy ciała (BMI) oraz liczba ciąż są kluczowymi czynnikami wpływającymi na ryzyko wystąpienia cukrzycy w badanej populacji.

Piąta publikacja "Prediction of Diabetes by Using Artificial Neural Network" została opublikowana w 2011 roku. Publikacja przedstawia wykorzystanie sztucznych sieci neuronowych (ANN) w przewidywaniu cukrzycy. Badanie obejmowało dane 250 pacjentów z cukrzycą w wieku od 25 do 78 lat, pochodzących z Pusat Perubatan Universiti Kebangsaan Malaysia, Kuala Lumpur. Zastosowano 27 cech (dane wejściowe) takich jak: ciśnienie krwi, poziom kreatyniny, pH moczu, poziom glukozy na czczo oraz inne. Dane zostały użyte do treningu sieci neuronowej przy użyciu narzędzi MATLAB Neural Network Toolbox. Celem

było przewidywanie ryzyka cukrzycy na podstawie analizowanych danych. Wyniki wykazały, że najlepszą dokładność przewidywania uzyskano przy użyciu algorytmu Bayesian Regularization, który osiągnął dokładność 88,8% oraz współczynnik korelacji $R = 0,99579$, wskazujący na doskonałe dopasowanie między wynikami rzeczywistymi a przewidywanymi. Najważniejsze zmienne wskazane w przewidywaniu cukrzycy to poziom glukozy na czczo.

Zestawienie wskazanych publikacji

	Rok publikacji	Dokładność	Liczność badanej próby	Zmienne wejściowe	Najistotniejsze cechy
1	2018	87,3%	1 004	9	Poziom glukozy, BMI
2	2021	93%	768	8	Liczba ciąż, BMI
3	2023	90,8%	15 000	8	Poziom glukozy, liczba ciąż, wiek, BMI
4	2020	88,7%	768	8	Poziom glukozy, BMI
5	2011	88,8%	250	27	Poziom glukozy

III. Sztuczne sieci neuronowe

Sztuczne sieci neuronowe (SSN) to systemy obliczeniowe stosowane szeroko w zadaniach takich jak klasyfikacja czy regresja. Są one rodzajem matematycznego modelu inspirowanego strukturą i działaniem ludzkiego mózgu, a ich podstawowym elementem są tzw. neurony, które współpracują ze sobą w ramach warstw sieci. Sztuczne sieci neuronowe uczą się na podstawie danych wejściowych, dostosowując swoje parametry (takie jak wagi połączeń między neuronami) w procesie zwanym uczeniem się (train), aby jak najlepiej odwzorować zależności między danymi a ich wynikami.

IV. Analiza wpływu różnych parametrów

W projekcie zbadaliśmy wpływ wybranych parametrów sztucznej sieci neuronowej na jakość jej działania. Analizie poddane zostały różne konfiguracje sieci, zmieniane zostały kolejno parametry takie jak: liczba neuronów, warstw, metoda optymalizacji, funkcja aktywacji, czy liczność próbki testowej.

Parametr	Wartość			
Liczba warstw	1	2	3	4
Liczba neuronów	4	8	16	32
Metoda uczenia	adam	rmsprop	adagrad	nadam
Rodzaj funkcji aktywacji	relu	sigmoid	tanh	softplus
Wielkość próby testowej	0,1	0,2	0,3	0,4

Wyniki zostały ocenione względem następujących miar:

- AC (Accuracy) – mierzy procent poprawnych przewidywań modelu,
- LOSS – wartość funkcji kosztu, reprezentuje różnicę między przewidywaniami modelu a rzeczywistymi wartościami,

- MSE (Mean Squared Error) – średni błąd kwadratowy,
- MAE (Mean Absolute Error) – średni błąd bezwzględny.

Wyniki zostały przedstawione w poniższych tabelach z podziałem na zbiory train (treningowy) i test (testowy) w celu oceny zarówno ogólnej skuteczności modelu, jak i możliwości jego przeuczenia. Badanie zostało przeprowadzone 5 razy dla każdej konfiguracji, a w tabelach znajdują się uśrednione wyniki.

Wpływ liczby neuronów w warstwie:

neurony	4		8		16		32	
	train	test	train	test	train	test	train	test
AC	0,8423	0,8206	0,9359	0,8990	0,9972	0,9678	1	0,9749
LOSS	0,3540	0,40267	0,1824	0,3248	0,0159	0,2159	0,00103	0,2591
MSE	0,1124	0,12395	0,0532	0,0796	0,0028	0,0280	4,57E05	0,0238
MAE	0,2294	0,2329	0,1236	0,1475	0,01371	0,0445	0,001	0,0276

Sztuczne sieci neuronowe zostały przetestowane kolejno z liczbami neuronów w warstwie: 4, 8, 16 i 32. Dokładność na zbiorze treningowym wzrasta wraz ze wzrostem liczby neuronów w warstwie (od 0,8423 dla 4 neuronów do nawet 1 dla 32 neuronów), podobny trend można zaobserwować również na zbiorze testowym (od 0,8206 dla 4 neuronów do 0,9749 dla 32 neuronów). Wartość LOSS na zbiorze treningowym maleje do bardzo małych wartości wraz ze wzrostem liczby neuronów (dla 32 neuronów wynosi 0,00103). Z kolei dla zbioru testowego wartości LOSS są wyraźnie wyższe (szczególnie dla 32 neuronów), co wskazuje na ryzyko przeuczenia przy wyższej liczbie neuronów. Dla metryk MSE i MAE wartości dla zbioru testowego są zawsze wyższe niż dla zbioru treningowego, ale maleją wraz ze wzrostem liczby neuronów. Ryzyko przeuczenia jest największe dla 32 neuronów w warstwie, kiedy różnice w wartościach pomiędzy zbiorami są duże.

Wpływ liczby warstw:

warstwy	1		2		3		4	
	train	test	train	test	train	test	train	test
AC	0,8547	0,8412	0,9395	0,8990	0,9525	0,9164	0,9533	0,9228
LOSS	0,3250	0,38292	0,1673	0,2833	0,1424	0,3144	0,1322	0,2988
MSE	0,10133	0,11547	0,0494	0,0765	0,0414	0,0677	0,0389	0,0618

MAE	0,2099	0,21432	0,1162	0,1381	0,0959	0,1192	0,0833	0,1047
-----	--------	---------	--------	--------	--------	--------	--------	--------

Zbadane zostały sztuczne sieci neuronowe o liczbie warstw od 1 do 4. Dokładność AC rośnie na obu zbiorach wraz ze wzrostem liczby warstw (do 0,9533 dla 4 warstw na zbiorze train i do 0,9228 na zbiorze test). Wartość funkcji LOSS maleje wraz ze wzrostem liczby warstw i jest jednocześnie zawsze wyższa dla zbioru test. Wskaźniki błędów maleją dla wyższych warstw, pogłębiają się również różnice między zbiorami (ale i tak są stosunkowo niewielkie). Podsumowując, można wnioskować, że duże liczby warstw w sieciach neuronowych prowadzą do wystąpienia ryzyka przeuczenia. W naszym badaniu dobór do 4 warstw jest jednak optymalny, wyniki charakteryzują się dużą dokładnością przy stosunkowo niedużych różnicach w wartościach między train a test.

Wpływ metody optymalizacji:

W analizie porównane zostały 4 optymalizatory:

- Adam,
- Nadam,
- RMSProp,
- Adagrad.

optymalizator	adam		rmsprop		adagrad		nadam	
	train	test	train	test	train	test	train	test
AC	0,928	0,8875	0,9442	0,8958	0,8122	0,8013	0,9260	0,8926
LOSS	0,2006	0,3286	0,14	0,4667	0,4016	0,4036	0,1967	0,3879
MSE	0,0595	0,0827	0,0417	0,0805	0,1294	0,1299	0,0582	0,0853
MAE	0,1352	0,1538	0,0894	0,1271	0,2654	0,2594	0,1328	0,1559

Najwyższa dokładność została uzyskana przy wykorzystaniu optymalizatora RMSProp (0,9442 dla train i 0,8958 dla test). Kolejno najlepiej poradziły sobie metody optymalizacji Nadam (0,8926) i Adam (0,8875), najsłabiej wypadł optymalizator Adagrad (0,8013). Miary błędów dla trzech najlepszych metod są niskie, nie przekraczają wartości około 0,16, natomiast dla Adagrad wartość MAE na poziomie 0,2654 może wskazywać na ograniczoną skuteczność tej metody. Podsumowując, najlepszymi optymalizatorami w badaniu są Adam i Nadam, obie metody charakteryzują się wysoką dokładnością, niskimi błędami i funkcją LOSS oraz są stabilne dla obu zbiorów.

Wpływ funkcji aktywacji:

Przetestowane zostały 4 rodzaje funkcji aktywacji:

- ReLU (Rectified Linear Unit) - funkcja przyjmuje wartość wejściową w niezmienionej formie, gdy jest dodatnia, a w przypadku wartości ujemnych zwraca zero,
- Sigmoid (funkcja logistyczna) - funkcja przekształca wartości wejściowe na przedział (0, 1),
- Tanh (funkcja hiperboliczna tangensowa) - funkcja skaluje wartości wejściowe na przedział (-1,1),
- Softplus - przekształca wyjścia sieci w rozkład prawdopodobieństwa tak, aby wynik zawierał się w przedziale (0,1), a suma prawdopodobieństw wynosiła 1.

Funkcja aktywacji	relu		sigmoid		tanh		softplus	
	train	test	train	test	train	test	train	test
AC	0,9199	0,8881	0,8671	0,8489	0,9492	0,9003	0,8685	0,8482
LOSS	0,2441	0,3347	0,3458	0,3542	0,1560	0,2553	0,2858	0,3594
MSE	0,0611	0,0879	0,1073	0,1138	0,0434	0,0745	0,0899	0,1063
MAE	0,1372	0,1610	0,2250	0,2248	0,1096	0,1437	0,1872	0,1966

Najlepszą funkcją aktywacji w tym badaniu jest tanh, funkcja osiąga najwyższą dokładność (0,9492 dla train i 0,9003 dla test), niskie wartości funkcji LOSS oraz najniższe miary błędów. Drugą najlepszą metodą jest funkcja ReLU, a najslabiej radzą sobie funkcje sigmoid i softplus – dokładność na poziomie około 0,87 dla train i 0,85 dla test, oraz najwyższe wartości błędów MSE i MAE.

Wpływ rozmiaru zbioru testowego:

Badanie zostało przeprowadzone dla próbek testowych liczących kolejno: 0,1; 0,2; 0,3, 0,4.


Próbka testowa	0,1		0,2		0,3		0,4	
	train	test	train	test	train	test	train	test
AC	0,9278	0,8289	0,9263	0,8821	0,9163	0,8759	0,9314	0,8874
LOSS	0,1860	0,5033	0,1836	0,3219	0,1941	0,2741	0,1689	0,4309
MSE	0,0555	0,1188	0,0540	0,0869	0,0595	0,0828	0,0505	0,0883
MAE	0,1253	0,1959	0,1224	0,1581	0,1331	0,1540	0,1176	0,1555

Dla zbioru testowego dokładność rośnie wraz ze wzrostem rozmiaru próbki (0,8289 dla 0,1 i 0,8874 dla 0,4), natomiast dla zbioru treningowego wyniki oscylują w granicach 92% - 93%. Wartości LOSS, MSE i MAE nie różnią się znacząco między próbkami. Najlepsze wyniki zostały uzyskane dla największej próbki 0,4, ale warto zauważyć, że model sprawdza się dobrze dla każdego zbioru testowego.

Kolejnym krokiem analizy jest ocena działania sztucznych sieci neuronowych w zależności od liczby epok uczenia. Skuteczność modelu została zbadana zarówno na danych uczących się (train), jak i testowych (test) z zastosowaniem wcześniej omawianych miar: AC, LOSS, MSE i MAE. W poniższych tabelkach zostały przedstawione wyniki uzyskane dla co dziesiątej epoki uczenia oraz dla pięciu kolejnych uruchomień sieci neuronowej. Wyniki dla drugiej iteracji zostały dodatkowo przedstawione na wykresach.

Dla AC:


	1		2		3		4		5	
	train	test	train	test	train	test	train	test	train	test
1	0,7997	0,8006	0,7666	0,7653	0,7293	0,7781	0,7624	0,7621	0,7652	0,7588
10	0,8674	0,8328	0,8246	0,8167	0,8425	0,8682	0,8688	0,8489	0,8356	0,8103
20	0,9006	0,8521	0,8508	0,8328	0,8619	0,8746	0,8702	0,8424	0,8439	0,8264
30	0,8992	0,8489	0,8674	0,8457	0,8646	0,8746	0,8826	0,8360	0,8729	0,8264
40	0,9088	0,8553	0,8577	0,8360	0,8715	0,8810	0,8936	0,8553	0,8950	0,8682
50	0,9102	0,8489	0,8660	0,8521	0,8826	0,8939	0,9116	0,8714	0,9033	0,8682
60	0,9102	0,8489	0,8771	0,8585	0,8840	0,8939	0,9116	0,8842	0,9199	0,8810
70	0,9227	0,8585	0,8785	0,8714	0,8840	0,8907	0,9088	0,8778	0,9227	0,8778
80	0,9323	0,8682	0,8785	0,8521	0,8950	0,8939	0,9199	0,8810	0,9323	0,9068
90	0,9323	0,8682	0,8964	0,8682	0,8936	0,9035	0,9199	0,8907	0,9296	0,8971
100	0,9282	0,8682	0,9033	0,8682	0,8950	0,8971	0,9351	0,9035	0,9351	0,9003



Dla 1 epoki dokładność na zbiorze testowym waha się w przedziale od 0,7588 do 0,8006. W miarę zwiększania liczby epok AC systematycznie rośnie i dla 100 epok wynosi od 0,8682 do 0,9035 na zbiorze testowym, co wskazuje na skuteczność sieci. Ponadto różnica w wartościach pomiędzy zbiorami uczącym się a testującym utrzymuje się zawsze na poziomie zaledwie kilku procent, zatem ryzyko przeuczenia się jest niewielkie.

Dla LOSS:

	1		2		3		4		5	
	train	test	train	test	train	test	train	test	train	test
1	0,4650	0,5274	0,4866	0,5260	0,5091	0,4391	0,4716	0,4672	0,4800	0,4436
10	0,3184	0,3632	0,3771	0,4013	0,3581	0,3321	0,3263	0,3716	0,3795	0,3803
20	0,2815	0,3277	0,3353	0,3687	0,3298	0,3118	0,2912	0,3434	0,3283	0,3646
30	0,2603	0,3246	0,3113	0,3472	0,3114	0,3002	0,2689	0,3323	0,2821	0,3499
40	0,2412	0,3125	0,2915	0,3212	0,2966	0,2839	0,2488	0,3114	0,2376	0,3200
50	0,2268	0,3079	0,2731	0,3042	0,2876	0,2812	0,2338	0,3000	0,2124	0,3042
60	0,2112	0,2951	0,2606	0,2948	0,2800	0,2819	0,2244	0,2944	0,1964	0,2945
70	0,1970	0,3089	0,2474	0,2925	0,2697	0,2820	0,2128	0,2762	0,1860	0,2933
80	0,1874	0,3043	0,2352	0,2936	0,2630	0,2810	0,2010	0,2724	0,1759	0,2876
90	0,1772	0,3133	0,2209	0,2882	0,2552	0,2748	0,1924	0,2605	0,1659	0,2714
100	0,1694	0,3238	0,2077	0,2860	0,2498	0,2705	0,1828	0,2600	0,1571	0,2593




Funkcja straty LOSS zmniejsza się wraz ze wzrostem liczby epok uczenia. Na początku LOSS waha się w przedziale od 0,4391 do 0,5274 dla test i w przedziale od 0,4650 do 0,5091 dla train, z kolei po 100 epokach LOSS spada do przedziału od 0,2593 do 0,3238 dla test i od 0,1571 do 0,2498 dla train. Ta zależność potwierdza skuteczność uczenia się sieci neuronowej w miarę zwiększania liczby epok.

Dla MSE:

	1		2		3		4		5	
	train	test	train	test	train	test	train	test	train	test
1	0,1457	0,2608	0,1606	0,1698	0,1718	0,1446	0,1541	0,1529	0,1613	0,1487
10	0,1109	0,2088	0,1202	0,1297	0,1118	0,1031	0,1024	0,1177	0,1212	0,1263
20	0,1048	0,1813	0,1057	0,1193	0,1017	0,0958	0,0902	0,1097	0,1037	0,1173
30	0,1049	0,1674	0,0980	0,1128	0,0960	0,0918	0,0823	0,1034	0,0877	0,1055


40	0,0996	0,1573	0,0917	0,1041	0,0915	0,0868	0,0761	0,0976	0,0731	0,0939
50	0,0989	0,1491	0,0860	0,0969	0,0885	0,0853	0,0701	0,0920	0,0639	0,0859
60	0,0958	0,1420	0,0821	0,0923	0,0863	0,0851	0,0667	0,0886	0,0592	0,0811
70	0,0960	0,1335	0,0779	0,0930	0,0828	0,0845	0,0639	0,0869	0,0556	0,0796
80	0,0936	0,1279	0,0737	0,0947	0,0806	0,0839	0,0592	0,0816	0,0517	0,0748
90	0,0909	0,1204	0,0692	0,0918	0,0783	0,0812	0,0571	0,0771	0,0488	0,0717
100	0,0890	0,1162	0,0648	0,0904	0,0770	0,0796	0,0536	0,0757	0,0454	0,0691



Błąd MSE maleje wraz ze wzrostem liczby epok – od wartości w przedziale 0,1446-0,2608 do wartości 0,0691-0,1162 dla zbioru testującego i od 0,1457-0,1718 do 0,0454-0,0890 dla zbioru uczącego się. Systematyczny spadek wartości MSE świadczy o poprawiającej się skuteczności działania sieci w miarę zwiększania liczby epok uczenia.

Dla MAE:

	1		2		3		4		5	
	train	test	train	test	train	test	train	test	train	test
1	0,2608	0,2594	0,3035	0,3090	0,3247	0,2885	0,2969	0,2887	0,3206	0,2965
10	0,2088	0,2151	0,2499	0,2514	0,2338	0,2177	0,2159	0,2212	0,2575	0,2567
20	0,1813	0,1955	0,2191	0,2239	0,2145	0,1983	0,1937	0,2053	0,2210	0,2292
30	0,1674	0,1878	0,2042	0,2105	0,2027	0,1865	0,1784	0,1922	0,1970	0,2125
40	0,1573	0,1790	0,1936	0,1976	0,1908	0,1728	0,1647	0,1789	0,1674	0,1879
50	0,1491	0,1738	0,1819	0,1838	0,1853	0,1680	0,1537	0,1687	0,1503	0,1718
60	0,1420	0,1687	0,1745	0,1755	0,1818	0,1655	0,1505	0,1661	0,1357	0,1581
70	0,1335	0,1644	0,1667	0,1729	0,1769	0,1630	0,1428	0,1592	0,1278	0,1531
80	0,1279	0,1603	0,1613	0,1753	0,1713	0,1593	0,1363	0,1545	0,1208	0,1452
90	0,1204	0,1555	0,1510	0,1680	0,1652	0,1529	0,1284	0,1445	0,1138	0,1374
100	0,1162	0,1533	0,1428	0,1635	0,1635	0,1501	0,1252	0,1421	0,1075	0,1327



Dla MAE zależność jest taka sama, obserwujemy malejące wartości MAE wraz ze wzrostem liczby epok – od wartości w przedziale 0,2594-0,3090 do wartości 0,1327-0,16,35 dla test i od 0,2608-0,3247 do 0,1075-0,1635 dla train. Wyniki te również potwierdzają, że w miarę uczenia się modelu wyniki są dokładniejsze.

V. Podsumowanie

Przeprowadzona przez nas analiza z wykorzystaniem sztucznych sieci neuronowych wskazała wpływ poszczególnych parametrów na skuteczność działania sieci. Możemy zaobserwować, że wzrost niektórych parametrów (liczby neuronów i warstw) przekładał się na dokładniejsze wyniki sieci, jednak jednocześnie stwarzał ryzyko wystąpienia problemu przeuczenia. Efektywność działania sieci była też zależna od wyboru optymalizatora, funkcji aktywacji czy liczności próbki testowej.

Porównując dane wejściowe z przytoczonymi publikacjami, możemy zauważyć, że w naszym zbiorze danych występują bardzo podobne zmienne. Zgodność, którą uzyskałyśmy przy użytych parametrach i metodach jest stosunkowo podobna do zgodności jakie zostały uzyskane w publikacjach, co może świadczyć o tym, że model działa podobnie skutecznie. Dokładność na zbiorze testowym w projekcie w większości przypadków mieści się w przedziale 82%-90%, co jest bliskie wynikom z publikacji.